

## EXERCICE 10. ESTIMATION D'UN PROPORTION

On veut estimer la proportion  $p$  d'étudiants qui dorment plus de 8 heures par nuit. Les observations sur un échantillon de 27 étudiants sont :

s= 11 étudiants dorment plus de 8 heures

f=16 étudiants dorment moins de 8 heures.

On note  $S$  la variable aléatoire qui représente le nombre d'étudiants qui dorment plus de 8 heures dans un échantillon de taille  $n = 27$ .

On envisage deux lois a priori sur le paramètre  $p \in ]0, 1[$  :

Modèle A- la loi discrète définie par

i	$b_i$	$P(p = b_i)$
1	0.05	0.03
2	0.15	0.18
3	0.25	0.28
4	0.35	0.25
5	0.45	0.16
6	0.55	0.07
7	0.65	0.03

Modèle B- la loi Beta de paramètres  $a = 3.4$  et  $b = 7.4$ .

Modèle C- la loi non informative de Jeffreys

### *Comparaison des trois modèles bayésiens*

- I-1) Représenter graphiquement les trois lois a priori.
  - I-2) Calculer la moyenne et la variance des trois lois a priori
  - I-3) Commenter les résultats obtenus. Les lois apportent-elles la même information a priori ?
  - I-4) Donner l'expression des trois lois marginales  $m(x) = P(X = x)$
  - I-5) En déduire la valeur du facteur de Bayes pour comparer
    - les modèles A et B.
    - les modèles B et C.
    - les modèles A et C.
- Commenter les résultats obtenus.

### *lois a posteriori*

- II-1) Calculer les trois lois a posteriori.
- II-2) Représenter sur un même graphique les lois a priori et les lois a posteriori
- II-3) Calculer la moyenne et la variance des lois a posteriori.
- II-4) Commenter les résultats obtenus.

### *Régions de confiance bayésiennes pour le paramètre $p$*

### Modèle a priori A

- III-1) Construire une région HPD de niveau 95% (ou au moins 95%) ? S'il est différent de 95% quel est le niveau exact de la région HPD.

### Modèle a priori B

- III-2) Calculer le plus court intervalle de crédibilité au niveau 95% en utilisant la fonction `qbeta`.  
 III-3) Quelle est la région HPD de niveau 95% ?

### Modèle a priori C

- III-4) Reprendre les questions précédentes pour le modèle C

### Conclusion

- III-5) Comparer et commenter les résultats obtenus

### Prévision

On veut prévoir  $S^*$  le nombre d'étudiants qui dorment plus de 8 heures dans un groupe de taille 20.

### Modèle a priori B

- VI-1) Trouver les fonctions  $a(S), b(S)$  pour que la valeurs  $s^*$  simulée à partir de l'algorithme ci-dessous soit une réalisation de la loi prédictive de  $S^*$ .  
 Quelle expression théorique de la loi prédictive permet de justifier cet algorithme ?

1. Simuler  $p$  suivant la loi beta de paramètre  $(a(S), b(S))$
2. Simuler  $s^*$  suivant la loi binomiale de paramètre  $(20, p)$

- VI-2) Simuler un échantillon de longueur  $M$  suivant la loi predictive de  $S^*$

- VI-3) A partir de l'échantillon simulé,

- (a) calculer et représenter graphiquement une approximation de la loi prédictive,
- (b) calculer une approximation de la région HPD de la loi prédictive au niveau 95 % (ou au moins 95%),
- (c) calculer une approximation du meilleur prédicteur ponctuel au sens de l'erreur  $L^2$

- VI-4) Reprendre les questions précédentes pour le modèle a priori C

- VI-5) Adapter l'algorithme précédent pour simuler un échantillon suivant la loi prédictive associée au modèle a priori A, puis reprendre les mêmes questions.

### Comparaison.

- VI-6) Représenter sur un même graphique les lois prédictives associées aux trois modèles.  
 VI-7) Comparer les régions HPD des lois prédictives de niveau 95 % (ou au moins 95%) et les prédicteurs ponctuels.  
 VI-8) Commenter les résultats